

# MARKETING CUSTOMER BEHAVIOUR ANALYSIS

## SUMMARY

14,91%

Customer Response Rate

0,94%

Customer Complaint Rate

29,78%

Total Acceptance Rate

D10

261

Accepted Rate

23,30%

Conversion Rate

D4

24

Accepted Rate

2,14%

Conversion Rate

D5

42

Accepted Rate

3,75%

Conversion Rate

D6

51

Accepted Rate

4,55%

Conversion Rate

D7

48

Accepted Rate

4,29%

Conversion Rate

D8

54

Accepted Rate

4,82%

Conversion Rate

D9

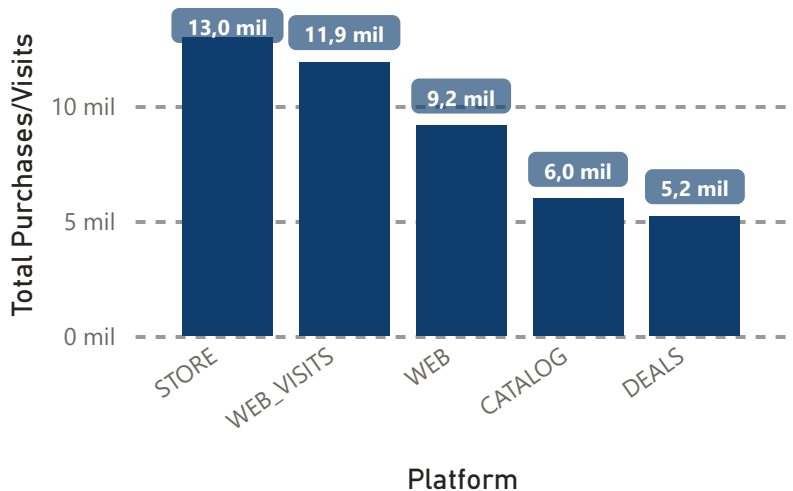
125

Accepted Rate


11,16%

Conversion Rate


Total Purchases/Visits by Platform




Total Customer by Recency Score



%Total Amount by Product



Accepted Rate by Income Decile



Campaign

Todas

Purchase Type

Todas

Product

Selección múltiple

Income Decile

D1

D5

D10

D6

D2

D7

D3

D8

D4

D9

Recency Score

2





4

3

5


# MARKETING CUSTOMER BEHAVIOUR ANALYSIS

## Campaign Analysis



Accepted Rate by Income Decile

Income Decile	Accepted Rate	% Accepted Rate
D5	42	32,81%
D3	26	20,31%
D4	24	18,75%
D1	23	17,97%
D2	13	10,16%



Income Decile

D1

D10

D2

D3

D4

D5

D6

D7

D8

D9

Recency Score

2

4

3

5

0,69%

Customer Complaint Rate

24%



Response Recency 90

724

Total Customers Recency

15,15

Recency Average by Decile



33,2 mil€



Income Average

0,7

KidHome Ratio

0,4

TeenHome Ratio



Product Name

FISH


MEAT

FRUITS

SWEET

GOLD

WINES



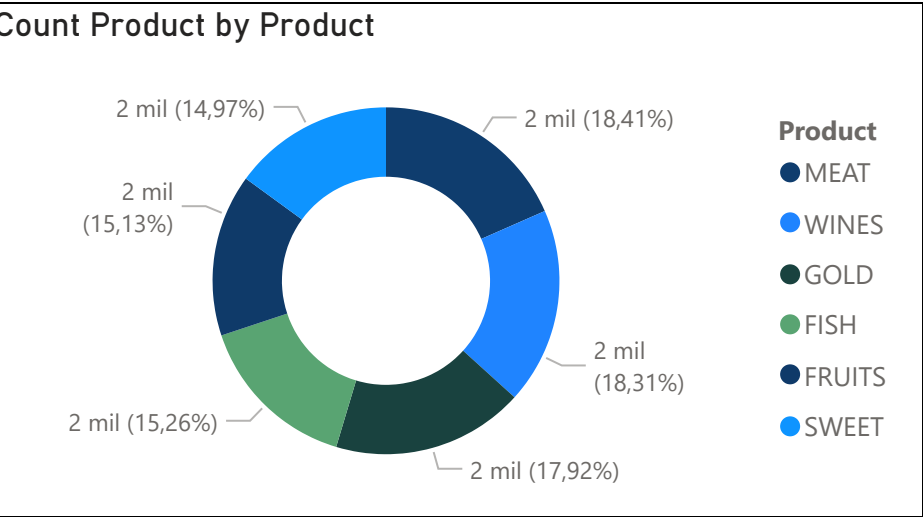
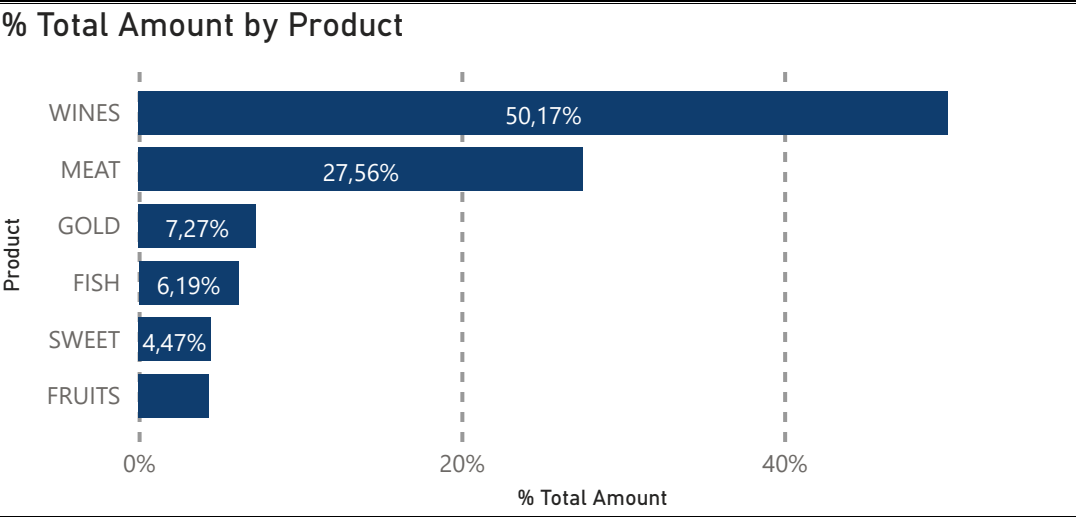
<div>WINES</div> <div>€ 305,71</div> <div>Revenue by Unit Sold</div>
<div>MEAT</div> <div>€ 167,02</div> <div>Revenue by Unit Sold</div>
<div>FISH</div> <div>€ 45,29</div> <div>Revenue by Unit Sold</div>
<div>GOLD</div> <div>€ 45,25</div> <div>Revenue by Unit Sold</div>
<div>SWEET</div> <div>€ 33,29</div> <div>Revenue by Unit Sold</div>
<div>FRUITS</div> <div>€ 32,02</div> <div>Revenue by Unit Sold</div>

Amount vs Recency Score by Product

Product_Name	2	3	4	5	Total
WINES	€57.579	€211.498	€196.203	€215.536	€680.816
MEAT	€36.417	€114.391	€104.451	€118.709	€373.968
GOLD	€9.298	€29.094	€29.100	€31.117	€98.609
FISH	€6.928	€24.894	€25.044	€27.191	€84.057
SWEET	€5.952	€18.316	€17.322	€19.031	€60.621
FRUITS	€5.192	€16.933	€17.521	€19.271	€58.917
Total	€121.366	€415.126	€389.641	€430.855	€1.356.988

Product Count by Name

Product_Name	Suma de Count	%TG Suma de Count
MEAT	2239	18,41%
WINES	2227	18,31%
GOLD	2179	17,92%
FISH	1856	15,26%
FRUITS	1840	15,13%
SWEET	1821	14,97%
Total	12162	100,00%



Purchase\_Type

CATALOG

STORE

DEALS

WEB

Income Decile

D1

D10

D2

D3

D4

D5


D6

D7


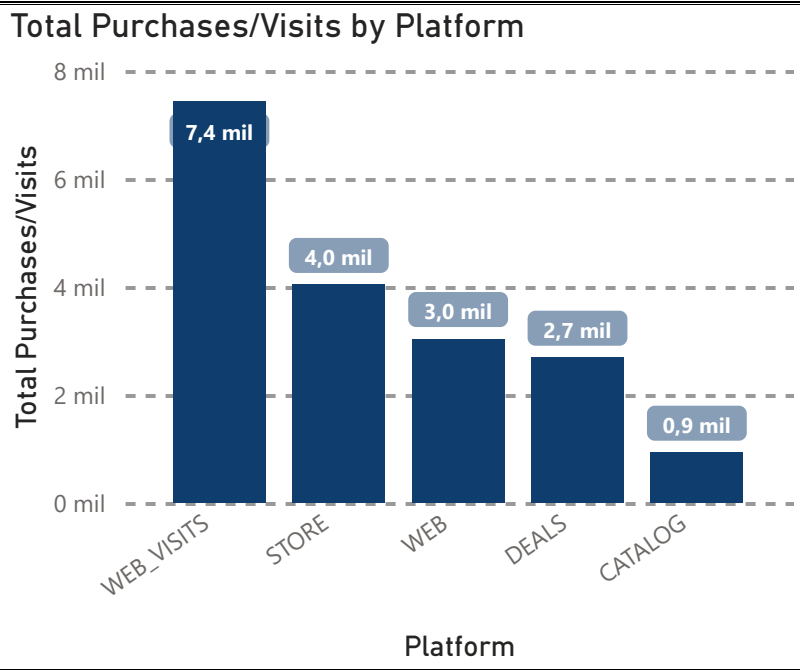
D8

D9

Total Purchases/Visits by Platform		
Platform	Purchases/Visits	% Total Purchases/Visits
CATALOG	931	5,13%
DEALS	2690	14,83%
WEB	3036	16,74%
STORE	4038	22,27%
WEB_VISITS	7441	41,03%
Total	18136	100,00%



Visits vs Recency Score by Platform					
Platform	2	3	4	5	Total
WEB_VISITS	669	2202	2108	2462	7441
STORE	417	1191	1118	1312	4038
WEB	313	896	804	1023	3036
DEALS	251	833	749	857	2690
CATALOG	87	289	284	271	931
Total	1737	5411	5063	5925	18136



# Power BI

# IBM Skillsbuild

*FASE 2*

**España 923**

## ANÁLISIS DEL COMPORTAMIENTO DEL CLIENTE

### PROYECTO FINAL

*Javier Blanco*

*Nov, 2023*

*Github repository*

[https://github.com/jblanco89/IBM\\_Datahack\\_Capstone-Project](https://github.com/jblanco89/IBM_Datahack_Capstone-Project)

# PLANTEAMIENTO

Para el proyecto final se ha facilitado un *dataset* donde encontramos registros de compra de productos, vía de compras (plataformas utilizadas) visitas a la página web, aceptación de intentos de campañas, entre otros campos, agrupados por cliente único. El *dataset* muestra un perfil de comportamiento de compra y respuesta de marketing por cada cliente, por lo que a priori se trata de una tabla de dimensiones más que una de hechos.

# SOLUCIÓN PROPUESTA

A nivel de análisis de datos, si queremos construir un modelo que se asemeje a lo visto durante el curso, es decir, siguiendo un esquema **tipo estrella**, se propone hacer uso de las funcionalidades de *PowerQuery* para transformar dicha tabla de dimensiones en una de hechos.

Gracias a esta transformación no solo hemos podido diseñar 7 tablas de dimensiones, si no además 3 tablas de hechos. Una de clientes por respuesta de campaña, otra de clientes por productos y otra de clientes por vía de compra. Esta transformación fue posible eliminando la dinamización de tablas (ver **figura**)


Table.RenameColumns("#Columnas reordenadas",{{"Z_CostContact", "Z_Cost"}})							
	Customer_ID	Year_Birth	Education	Marital_Status	Income	Kidhome	
1	0	1985	GRADUATION	MARRIED	70.951,00	0	
2	1	1961	GRADUATION	SINGLE	57.091,00	0	
3	9	1975	MASTER	SINGLE	46.098,00	1	
4	13	1947	PHD	WIDOW	25.358,00	0	
5	17	1971	PHD	MARRIED	60.491,00	0	
6	20	1965	2N CYCLE	MARRIED	46.891,00	0	
7	22	1976	GRADUATION	DIVORCED	46.310,00	1	
8	24	1960	MASTER	TOGETHER	17.144,00	1	

Pivot table



	Customer_ID	Campaign_ID	Acceptance	
1	0	5	0	
2	0	2	0	
3	0	1	0	
4	0	3	0	
5	0	4	0	
6	1	2	1	
7	1	4	0	
8	1	5	0	
9	1	1	0	
10	1	3	0	
11	9	4	0	
12	9	5	0	
13	9	3	0	
14	9	2	0	
15	9	1	0	
16	13	2	0	

Unpivot table



# ETL

Todo el proceso de Extracción, Transformación y carga de los datos desde el archivo CSV hasta el motor **PowerBI** fue llevado a cabo utilizando las robustas funcionalidades de **PowerQuery**. Gracias a esa herramienta se ha logrado:

- 1. Cambio y detección de tipos de datos
- 2. Cálculos derivados de los campos fecha (edad del cliente, antigüedad)
- 3. Limpieza, extracción y transformación de los campos tipo Texto, como: Educación y estado civil
- 4. Creación de tablas de dimensiones: *CustomerDim*, *ProdcutDim*, *CampaignDim*, *CampaignValueDim*, *PlatformDim*.
- 5. Se ha hecho una distinción entre los campos socio-demográficos del cliente: estado civil, educación, año de nacimiento, etc. y los campos de valor del cliente de cara a las campañas: *Recency*, *Z-cost*, *Complaints*, *Response* y *Revenue*.
- 6. Se eliminaron datos en blanco o erróneos, los cuales representaban menos del **1%** del *dataset*.

Se ha obtenido el siguiente resultado (**Ver figura**)

Consultas [11] < X ✓ fx = Table.RenameColumns(#"Columnas reordenadas",{{"Z\_CostContact", "Z\_Cost"}}) v

	123 Customer_ID	123 Year_Birth	A8C Education	A8C Marital_Status	\$
1		0	1985 GRADUATION	MARRIED	
2		1	1961 GRADUATION	SINGLE	
3		9	1975 MASTER	SINGLE	
4		13	1947 PHD	WIDOW	
5		17	1971 PHD	MARRIED	
6		20	1965 2N CYCLE	MARRIED	
7		22	1976 GRADUATION	DIVORCED	
8		24	1960 MASTER	TOGETHER	
9		25	1958 GRADUATION	MARRIED	
10		35	1987 GRADUATION	MARRIED	
11		48	1964 GRADUATION	TOGETHER	
12		49	1970 GRADUATION	SINGLE	
13		55	1963 GRADUATION	TOGETHER	
14		67	1972 MASTER	SINGLE	
15		73	1953 PHD	SINGLE	
16		75	1982 2N CYCLE	TOGETHER	
17		78	1969 GRADUATION	MARRIED	
18		87	1981 2N CYCLE	MARRIED	
19		89	1975 2N CYCLE	MARRIED	
20		92	1988 GRADUATION	SINGLE	
21		113	1951 GRADUATION	MARRIED	



# ESQUEMA FINAL DEL MODELO DE DATOS

Una vez las tablas han sido cargadas a **PowerBI** se ha procedido a su modelado. El resultado de este se asemeja más al estilo "constelación" o *Starflake*, siendo una versión mejorada entre el esquema estrella y el esquema copo de nieve.

Tal como puede verse en la imagen adyacente, tenemos:

- 3 tablas de hechos
- 7 tablas de dimensiones
- 2 tablas estabilizadoras (*Outriggers*)
- 1 tabla auxiliar (medidas **DAX**)


Tablas de hechos

Tablas de dimensiones

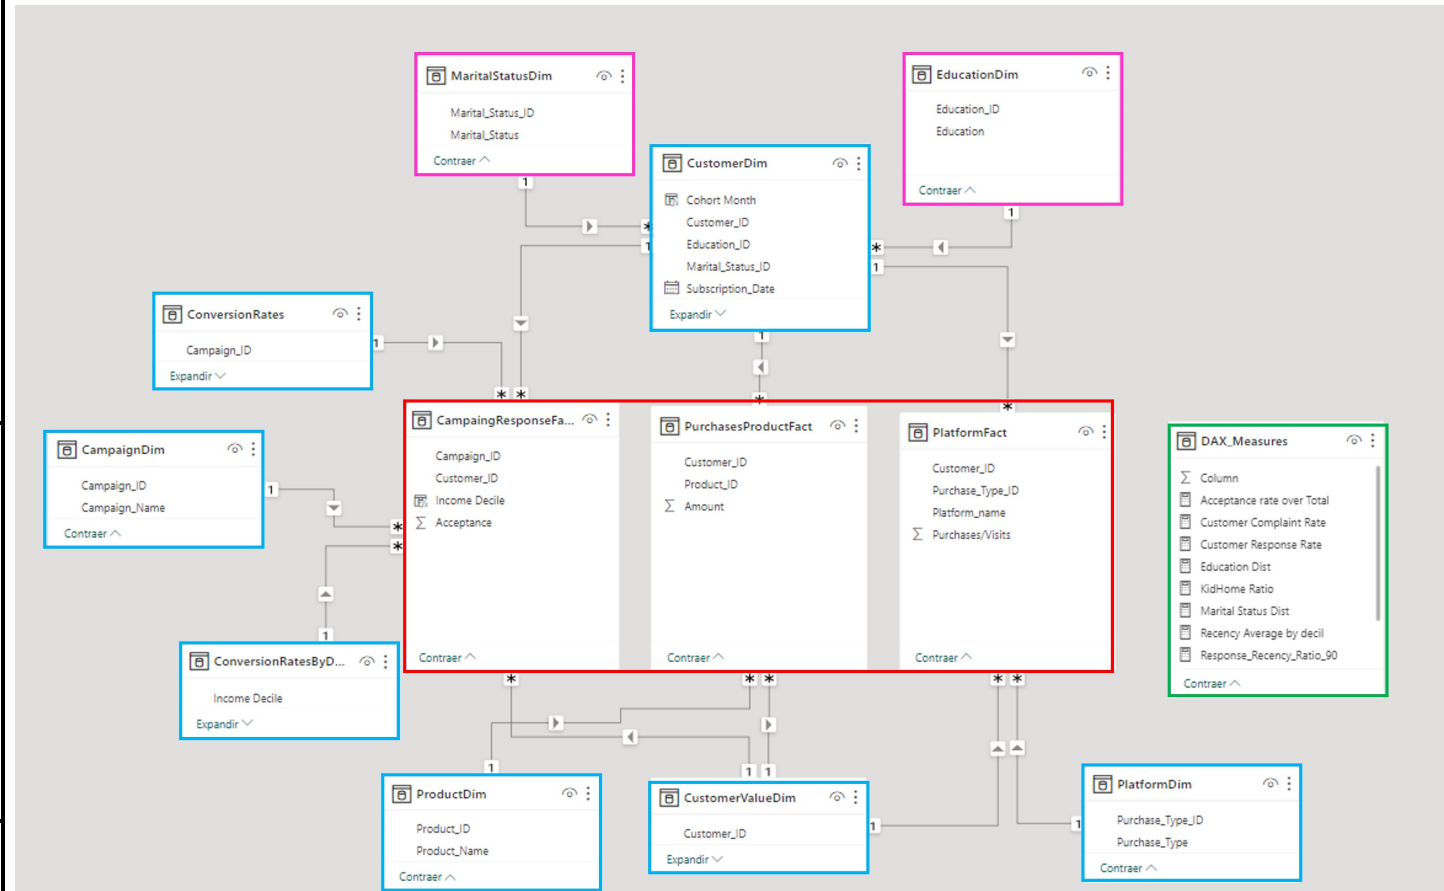
Tablas auxiliares

Tablas estabilizadoras  
(*Outriggers*)

Esquema de constelación



Saber más sobre el esquema  
Starflake, ver [aquí](#)



# MÉTRICAS E INDICADORES CALCULADOS (DAX)

## Customer Reponse Rate:

CRR = Clientes que han respondido a alguna campaña / numero total de clientes

## Customer Complaint Rate:

CCR = Clientes que se han quejado / numero total de clientes

## Total Acceptance Rate:

CAR = Clientes que se han aceptado la campaña / numero total de clientes

## KidHome & TeenHome Ratios:

Proporción de niños y adolescentes sobre el total de clientes. Puede ser filtrado por deciles o por recency score

## Income Decile:

ID = Percentiles del 1 al 10 sobre los ingresos de cada cliente. Clientes del Decil D10 tienen mayores ingresos.

## Recency Score:

RS = Discretización de los valores de recency del cliente. Un cliente con mayor score tendrá el menor recency.

## Response Recency 90:

RR90 = Clientes que han respondido alguna campaña a recency < 90 días / numero total de clientes en el mismo periodo a recency menor de 90

## Recency Average By Decile:

RAD = Promedio Recency de cliente por decil al que pertenece

```
1 Income Decile =
2 VAR Decile10 = PERCENTILE.INC(CustomerDim[Income], 0.1)
3 VAR Decile20 = PERCENTILE.INC(CustomerDim[Income], 0.2)
4 VAR Decile30 = PERCENTILE.INC(CustomerDim[Income], 0.3)
5 VAR Decile40 = PERCENTILE.INC(CustomerDim[Income], 0.4)
6 VAR Decile50 = PERCENTILE.INC(CustomerDim[Income], 0.5)
7 VAR Decile60 = PERCENTILE.INC(CustomerDim[Income], 0.6)
8 VAR Decile70 = PERCENTILE.INC(CustomerDim[Income], 0.7)
9 VAR Decile80 = PERCENTILE.INC(CustomerDim[Income], 0.8)
10 VAR Decile90 = PERCENTILE.INC(CustomerDim[Income], 0.9)
11
12 RETURN
13 SWITCH(
14     TRUE(),
15     CustomerDim[Income] <= Decile10, "D1",
16     CustomerDim[Income] <= Decile20, "D2",
17     CustomerDim[Income] <= Decile30, "D3",
18     CustomerDim[Income] <= Decile40, "D4",
19     CustomerDim[Income] <= Decile50, "D5",
20     CustomerDim[Income] <= Decile60, "D6",
21     CustomerDim[Income] <= Decile70, "D7",
22     CustomerDim[Income] <= Decile80, "D8",
23     CustomerDim[Income] <= Decile90, "D9",
24     TRUE(), "D10"
25 )
26
```